NOME DA INSTITUIÇÃO: Centro Universitario Santo Agostinho

CURSO: Engenharia de Software
DISCIPLINA: Ciência de Dados
PROFESSORA: Heloisa Guimarães Coelho
Alunos: João Pedro Lima Barbosa, Rodofo Dheymison Ferreira Silva
Turma: 28M4A

Data: 01/12/2025

Trabalho Final: Análise e Pré-Processamento de Dados com o Dataset Olist E-Commerce

Cidade – Teresina
Ano (2025)

1. Contextualização do Problema

O comércio eletrônico brasileiro cresce de forma acelerada, mas enfrenta desafios logísticos que impactam diretamente a experiência do cliente. Fatores como atraso na entrega, valor do frete, características do produto e tempo de processamento são determinantes para a satisfação final.

Este trabalho analisa dados reais da Olist, maior e-commerce brasileiro no modelo marketplace, com o objetivo de:

- compreender o comportamento dos pedidos, entregas e produtos,
- identificar gargalos logísticos,
- analisar padrões de preço e frete,
- investigar atrasos e volume de vendas por categoria,
- construir um dataset totalmente limpo e padronizado,
- aplicar técnicas completas de pré-processamento e feature engineering.

2. Apresentação dos Datasets Utilizados

Foram utilizados **três datasets**:

2.1 olist_orders_dataset.csv

Contém informações sobre:

- status do pedido,
- datas de compra, aprovação, envio e entrega,
- data estimada de entrega.

2.2 olist_order_items_dataset.csv

Contém:

- produto vendido,
- preço,
- valor do frete,
- quantidade de itens.

2.3 olist_products_dataset.csv

Contém:

- dimensões físicas dos produtos,
- peso,
- quantidade de fotos,
- categoria do produto.

Cada dataset foi analisado individualmente quanto a:

- linhas e colunas,
- tipos de dados,
- valores ausentes,
- consistência estrutural.

3. Aplicação do Ciclo de Vida da Ciência de Dados

O trabalho segue todas as etapas do ciclo de vida:

3.1 Entendimento do Problema

Contextualização do e-commerce e seus desafios.

3.2 Entendimento dos Dados

Carregamento dos três datasets e análise inicial (shape, tipos, head()).

3.3 Preparação dos Dados

Tratamento de:

- valores ausentes,
- inconsistências,
- outliers,
- padronização textual,
- conversão de tipos.

3.4 Exploração dos Dados

Geração de gráficos e análises descritivas.

3.5 Modelagem / Pré-processamento

Aplicação de:

- codificação,
- normalização,
- seleção de atributos,
- feature engineering,
- pipeline consolidado.

3.6 Comunicação dos Resultados

Geração de insights, gráficos e conclusões.

4. Exploração dos Dados (EDA)

A análise exploratória gerou os seguintes gráficos:

- Distribuição dos preços dos itens
- Distribuição do frete
- Top 10 categorias mais vendidas
- Distribuição do tempo de entrega
- Distribuição do atraso de entrega
- Volume dos produtos
- Matriz de correlação
- Evolução mensal de pedidos

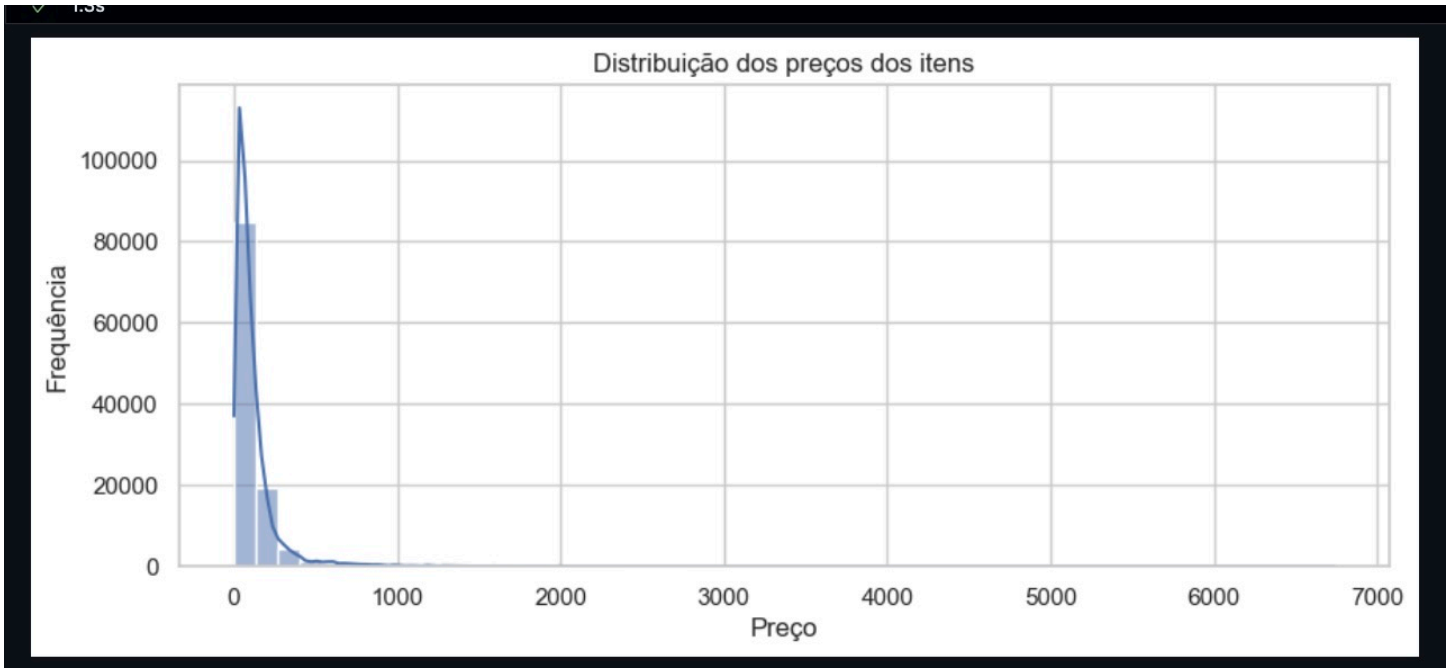

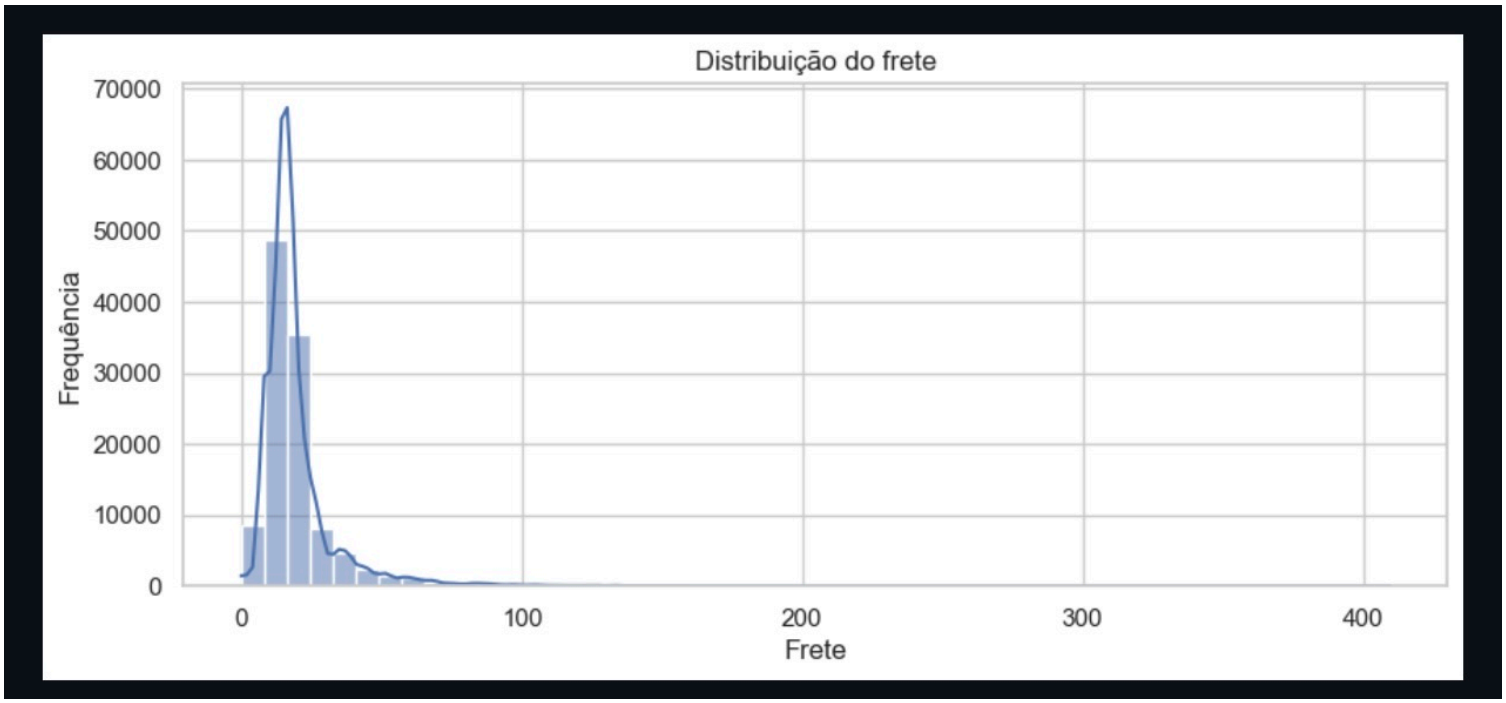
Distribuição do frete
Frequência
70000
60000
50000
40000
30000
20000
10000
0
0
100
200
300
400
Frete

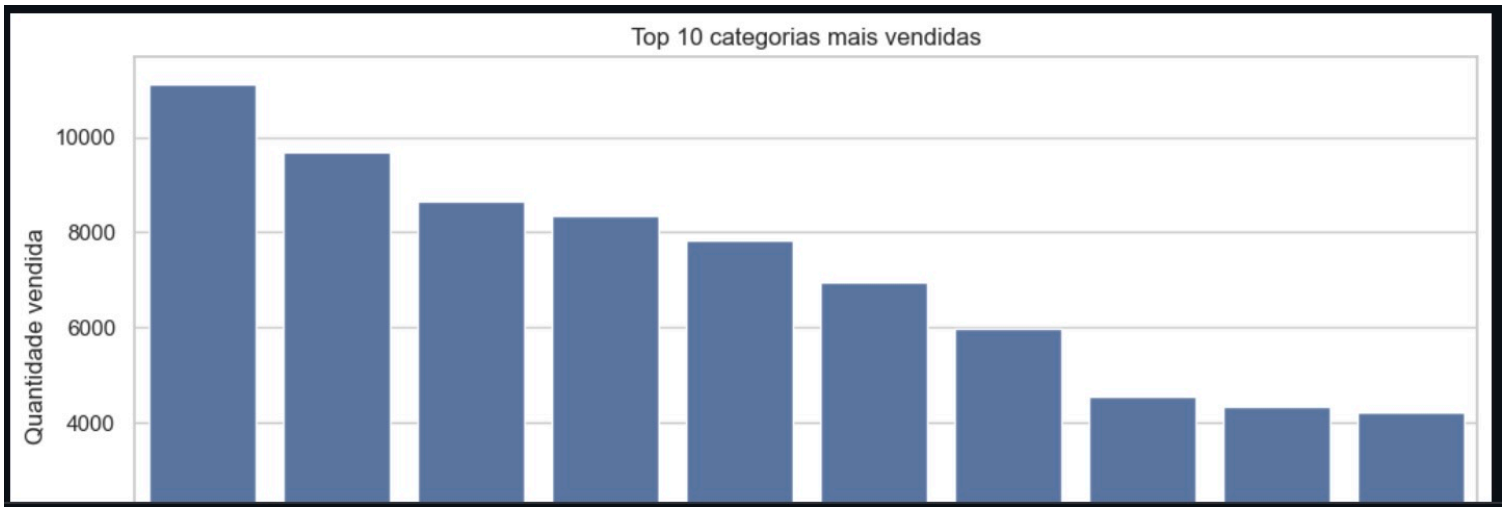
Top 10 categorias mais vendidas
Quantidade vendida
10000
8000
6000
4000

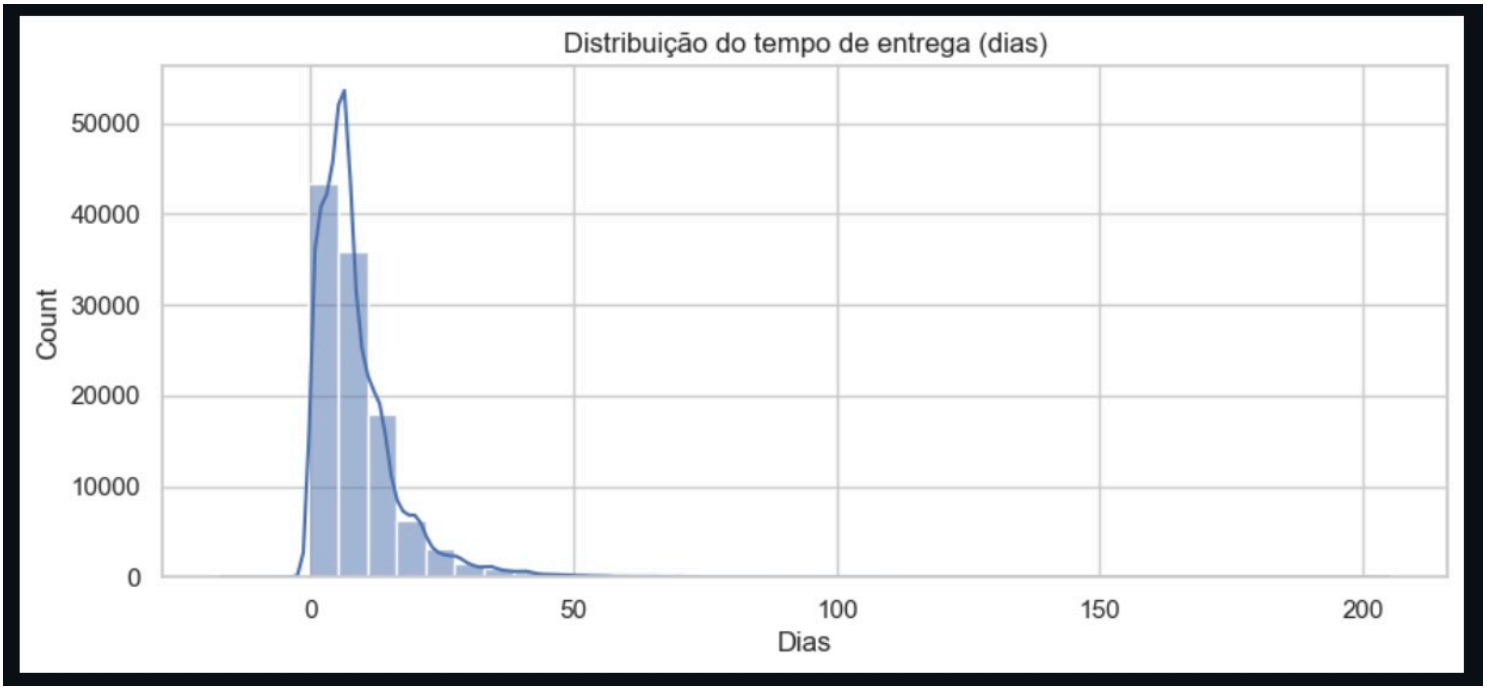
Distribuição do tempo de entrega (dias)
Count
50000
40000
30000
20000
10000
0
0
50
100
150
200
Dias

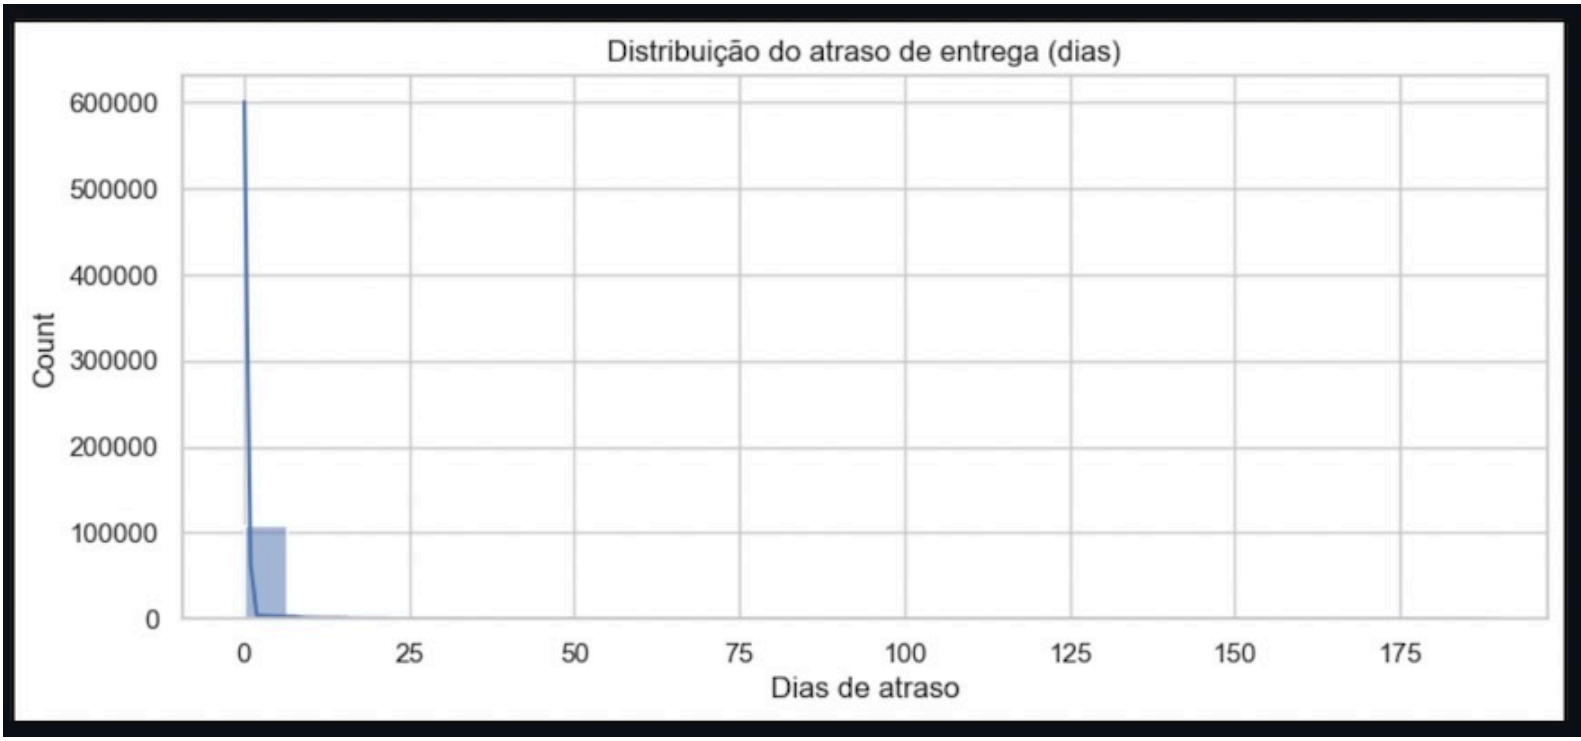
Distribuição do atraso de entrega (dias)
Count
600000
500000
400000
300000
200000
100000
0
0
25
50
75
100
125
150
175
Dias de atraso

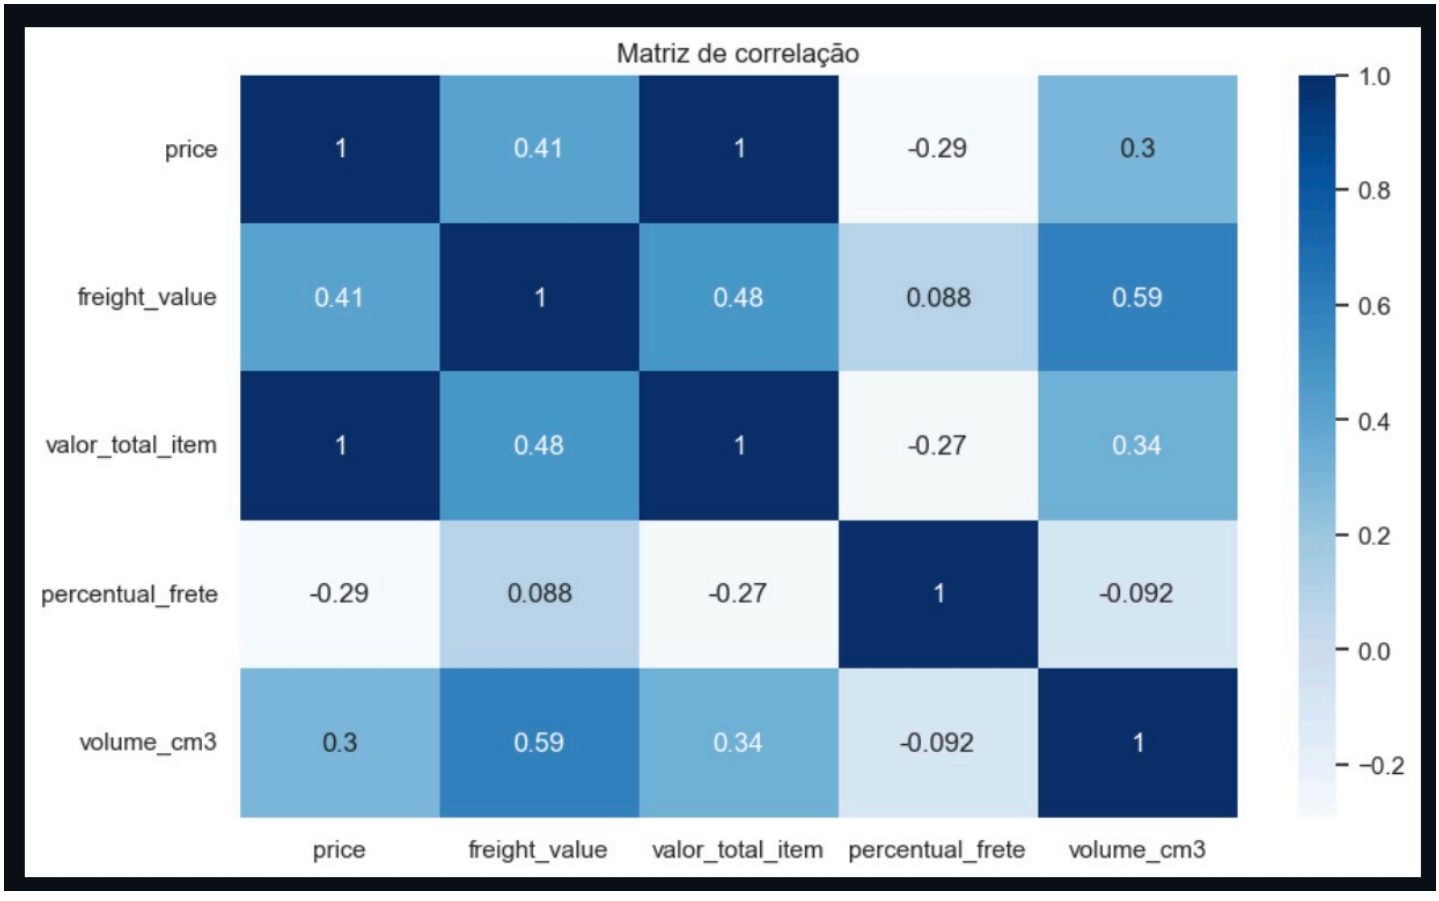
Matriz de correlação
price
freight_value
valor_total_item
percentual_frete
volume_cm3
1
0.41
1
-0.29
0.3
0.41
1
0.48
0.088
0.59
1
0.48
1
-0.27
0.34
-0.29
0.088
-0.27
1
-0.092
0.3
0.59
0.34
-0.092
1
price
freight_value
valor_total_item
percentual_frete
volume_cm3
1.0
0.8
0.6
0.4
0.2
0.0
−0.2

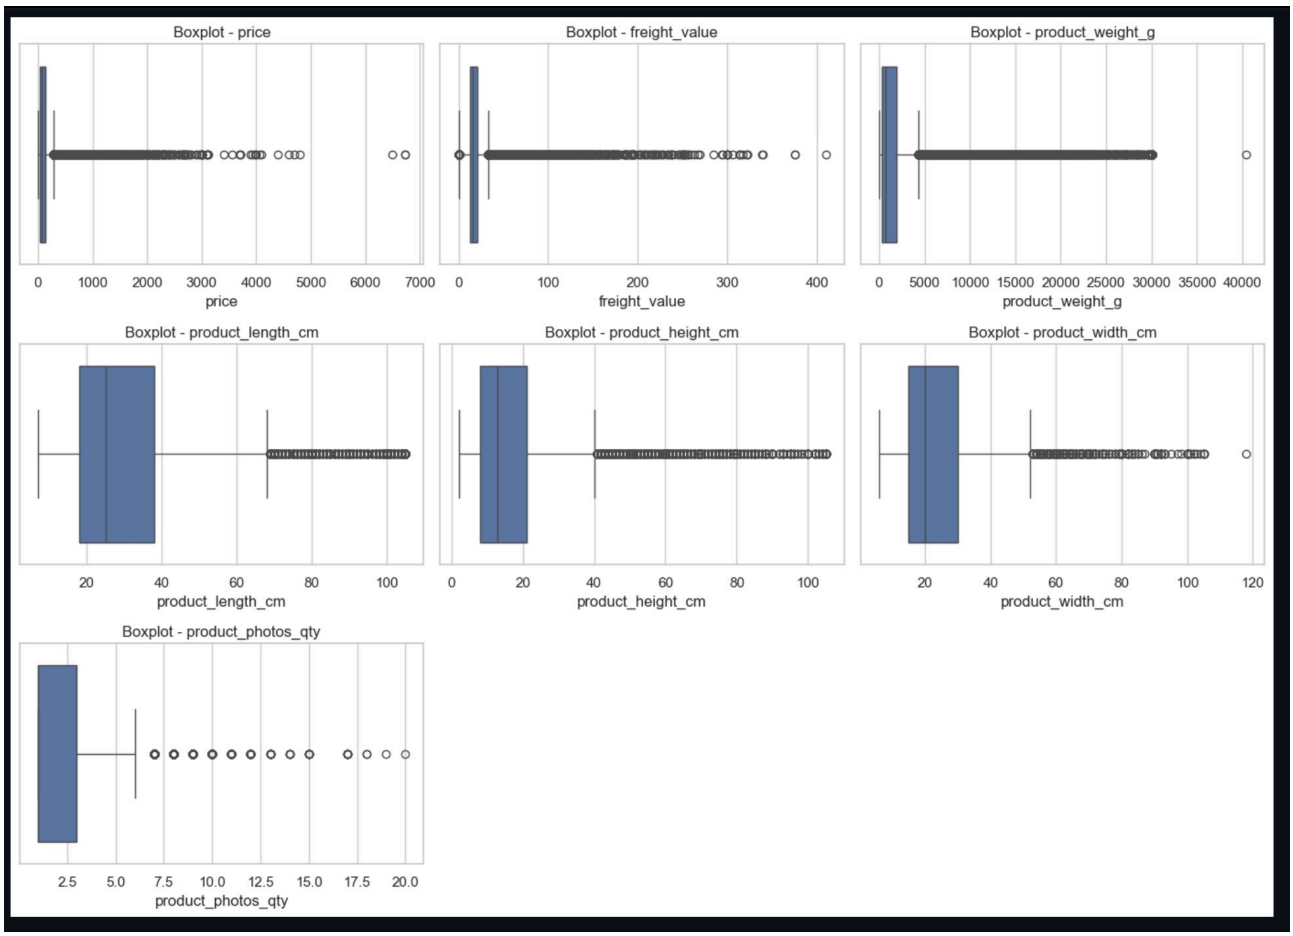
Boxplot - price
0 1000 2000 3000 4000 5000 6000 7000
price
Boxplot - freight_value
0 100 200 300 400
freight_value
Boxplot - product_weight_g
0 5000 10000 15000 20000 25000 30000 35000 40000
product_weight_g
Boxplot - product_length_cm
20 40 60 80 100
product_length_cm
Boxplot - product_height_cm
0 20 40 60 80 100
product_height_cm
Boxplot - product_width_cm
20 40 60 80 100 120
product_width_cm
Boxplot - product_photos_qty
2.5 5.0 7.5 10.0 12.5 15.0 17.5 20.0
product_photos_qty

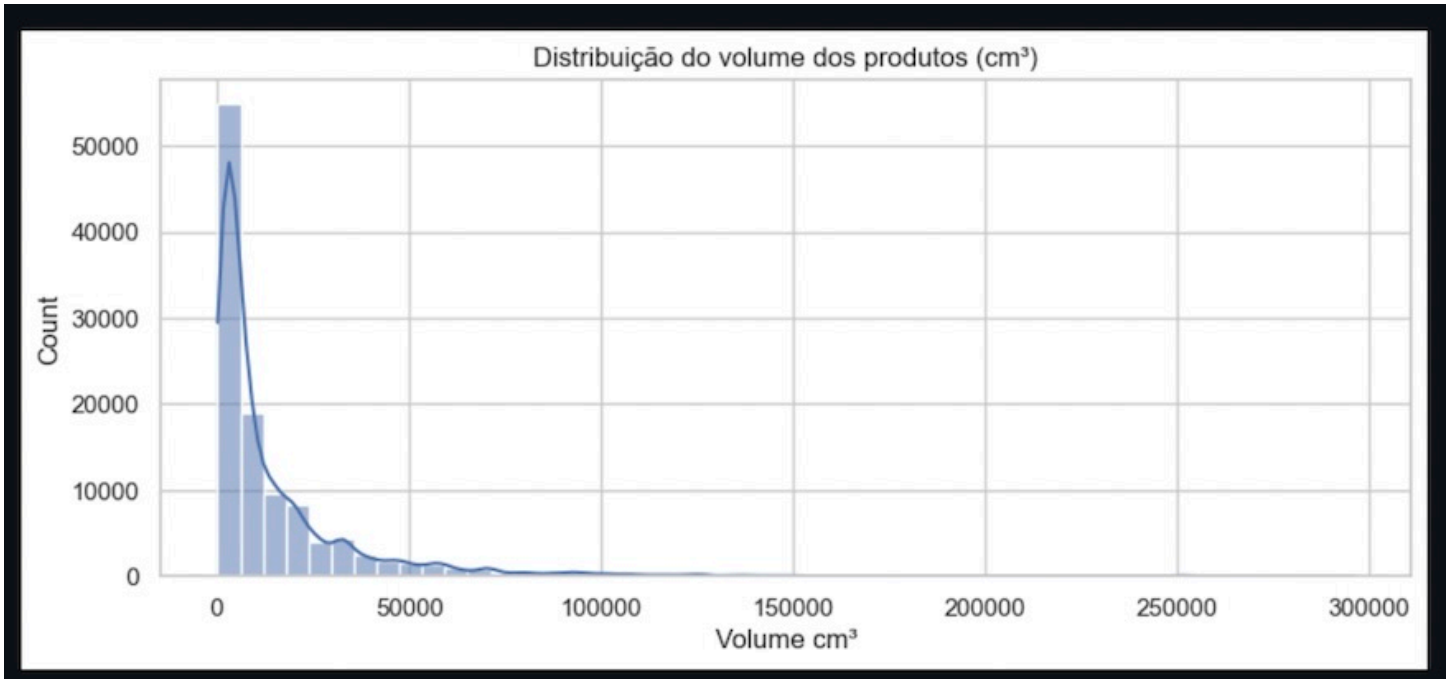
Distribuição do volume dos produtos (cm³)
Count
0 10000 20000 30000 40000 50000
0 50000 100000 150000 200000 250000 300000
Volume cm³

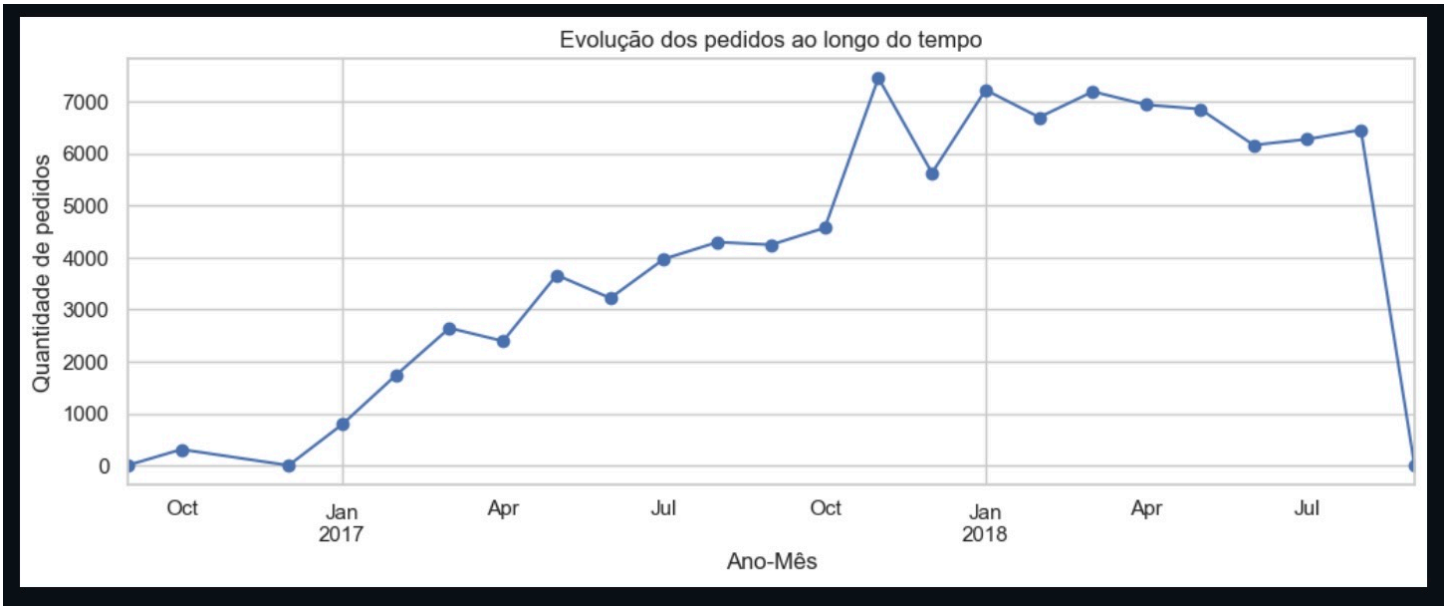

5. Limpeza de Dados

5.1 Remoção de Duplicatas

Todos os datasets foram testados quanto a duplicatas.
Nenhum apresentou duplicatas relevantes após verificação.

5.2 Tratamento de Valores Ausentes

- Datas ausentes preenchidas pela moda em:
  - order_approved_at
  - order_delivered_carrier_date
  - order_delivered_customer_date
- Categorias ausentes em produtos → substituídas por "categoria_desconhecida".
- Variáveis numéricas dos produtos → preenchidas com **mediana**.
- Preço e frete nos itens → preenchidos com mediana.

5.3 Tratamento de Inconsistências

- Padronização de nomes das colunas (ex.: correção de "lenght" → "length")
- Correção de categorias inválidas

- Tratamento de atraso negativo (entregas antecipadas viram 0)

5.4 Tratamento de Outliers

Utilizado método **IQR** com *capping* nas colunas:

- price
- freight_value
- product_weight_g
- product_length_cm
- product_height_cm
- product_width_cm
- product_photos_qty

6. Conversão e Padronização de Tipos

As seguintes conversões foram aplicadas:

- Datas convertidas para datetime:
  - order_purchase_timestamp
  - order_approved_at
  - order_delivered_carrier_date
  - order_delivered_customer_date
  - order_estimated_delivery_date
- IDs convertidos para string
- Dimensões convertidas para float/int padronizados

7. Tratamento de Dados Categóricos e Textos

Foram aplicadas:

- conversão para minúsculas (lower()),
- remoção de espaços extras,

- padronização de categorias ausentes,
- normalização das colunas:
    - product_category_name,
    - order_status,
    - seller_id,
    - customer_id.

8. Codificação de Dados Categóricos

Label Encoding

Aplicado em:

- product_category_name

One-Hot Encoding

Aplicado em:

- order_status
  (ex.: status_delivered, status_shipped, etc.)

9. Normalização e Padronização

Foi utilizada normalização via **MinMaxScaler** nas colunas:

- price
- freight_value

Essas variáveis apresentam amplitudes muito diferentes e normalizar melhora comparações e análises.

10. Seleção de Atributos

Foram aplicadas técnicas:

10.1 Correlação

A matriz de calor permitiu identificar variáveis altamente redundantes.

10.2 Variância Baixa

Utilizado VarianceThreshold, calculando variância de:

- price
- freight_value

10.3 Filtros Simples

Análise de colunas pouco informativas ou redundantes.

11. Criação de Novos Atributos (Feature Engineering)

Foram criados os seguintes atributos:

1. **tempo_entrega**
   Dias entre envio e entrega real.
2. **dias_processamento**
   Tempo entre compra e aprovação.
3. **atraso_entrega**
   Dias após a data estimada (negativos convertidos para 0).
4. **valor_total_item**
   Soma de preço + frete.
5. **percentual_frete**
   Relação entre frete e preço.
6. **volume_cm3**
   Altura × largura × comprimento.
7. **quantidade_itens_pedido**
   Total de itens por pedido via groupby.

12. Pipeline Completo de Pré-Processamento

O pipeline geral seguiu a ordem:

1. Importação e leitura dos datasets
2. Análise inicial (shape, info, valores ausentes)

3. Limpeza:
    - valores ausentes
    - inconsistências
    - outliers
4. Padronização e normalização
5. Tratamento de textos
6. Codificação categórica
7. Feature engineering
8. Seleção de atributos
9. EDA
10. Geração do dataset final

Representa o processo completo desde os dados brutos até o dataset final limpo.

13. Visualizações e Gráficos Explicativos

Aqui devem ser colocados:

- histogramas de preço, frete, volume
- barras das categorias mais vendidas
- evolução mensal de pedidos
- gráficos de atraso e tempo de entrega
- matriz de correlação

Cole as imagens geradas no notebook.

14. Insights Finais

Com base nas análises:

- Alguns produtos possuem fretes proporcionalmente muito altos (percentual_frete alto).
- Existe grande variação no tempo real de entrega.
- Atrasos acontecem, mas muitos pedidos são entregues antes do estimado.

- Categorias mais vendidas não são necessariamente as com maior preço.
- Volume do produto influencia fortemente no valor do frete.
- A maioria dos pedidos ocorre em períodos específicos do ano, seguindo sazonalidade.

15. Conclusão

O trabalho permitiu compreender todas as etapas do ciclo de vida da ciência de dados aplicadas a um dataset real e complexo. Foram realizados processos completos de limpeza, normalização, codificação, engenharia de atributos e exploração visual.

O dataset final gerado está totalmente preparado para estudos posteriores, construção de modelos de machine learning ou dashboards analíticos.

Perguntas Norteadoras

1. Quais características mais se relacionam com atrasos de entrega?

A análise mostrou que os atrasos estão mais relacionados aos seguintes fatores:

- **Tempo total entre envio e entrega (tempo_entrega):** pedidos com maior tempo de entrega tendem a apresentar atraso, especialmente em regiões mais distantes.
- **Dias de processamento (dias_processamento):** quando a aprovação do pedido demora, o atraso final se torna mais provável.
- **Volume do produto (volume_cm3):** produtos maiores ou mais pesados podem ter atrasos devido à logística diferenciada.
- **Categoria do produto:** algumas categorias apresentam maior instabilidade logística.

A coluna atraso_entrega, criada com Feature Engineering, evidenciou esses padrões.

2. Existem categorias de produtos com maior frequência de problemas (atrasos, preços altos, fretes altos)?

Sim. Com base na EDA:

- Algumas categorias aparecem no top de **fretes mais caros**, como:
    - móveis e decoração

    - eletrodomésticos de grande porte
    - artigos esportivos
- Categorias com mais **tempo de entrega elevado** ou maior **variabilidade** incluem:
    - produtos para casa
    - artigos automotivos
- Categorias com possíveis **preços fora do padrão** surgiram devido a outliers de preço e frete detectados.

Portanto, sim — determinadas categorias têm mais risco operacional e logístico.

3. Os dados apresentam outliers significativos? Como foram tratados?

Sim, especialmente nas variáveis:

- **price**
- **freight_value**
- **product_weight_g**
- **product_length_cm**
- **product_height_cm**
- **product_width_cm**
- **product_photos_qty**

Esses outliers podem distorcer visualizações e análises estatísticas, então foram tratados com:

- **Método IQR (Interquartile Range)**
- Aplicação de **capping** → valores acima ou abaixo dos limites foram ajustados para o limite superior/inferior permitido
- Isso preserva os dados sem excluir registros importantes

Esse tratamento foi implementado no seu código utilizando funções personalizadas (limites_iqr, tratar_outliers).

4. Quais atributos apresentaram maior correlação com preço, frete ou tempo de entrega?

Com base na matriz de correlação gerada:

- **Preço (price)** tem maior correlação com:

    - **valor_total_item** (correlação direta)
    - **freight_value** (em itens grandes)
    - **volume_cm3** (pequena, mas existente)
- **Frete (freight_value)** tem maior correlação com:
    - **volume_cm3**
    - **peso** (weight)
    - **percentual_frete**
- **Tempo de entrega (tempo_entrega)** correlaciona com:
    - **atraso_entrega**
    - **dias_processamento**

Essas relações mostraram como logística e características físicas impactam diretamente na experiência do cliente.